Nama : Justine Carneggie

NIM : 2802525016

A. Analisis Konseptual (Bobot: 20%)

1. Saat pelatihan, Batch Normalization menormalisasi aktivasi memakai rata-rata dan varians mini-batch (Slide 6–7). Karena mini-batch diambil secara acak, kedua statistik itu hanyalah estimasi berderau dari statistik populasi, sehingga keluaran sebuah sampel bergantung pada sampel lain yang kebetulan satu batch dengannya. Derau stokastik ini mencegah jaringan menghafal aktivasi persis per sampel dan bekerja mirip Dropout, sehingga disebut mild regularization (Slide 8; Ioffe & Szegedy, 2015). Derau mengecil bila ukuran batch membesar. Asumsi "menghilangkan Dropout" tidak berlaku ketika model sangat besar dibanding datanya sehingga regularisasi BN yang lemah tidak cukup, atau ketika batch sangat kecil sehingga statistik terlalu berderau dan pelatihan menjadi tidak stabil. Menaruh Dropout sebelum BN juga menimbulkan variance shift antara fase latih dan inferensi, sehingga performa justru turun (Li dkk., 2019).
2. Pada plain CNN yang makin dalam, galat pelatihan ikut naik. Ini bukan overfitting, melainkan masalah optimasi (Slide 10; He dkk., 2016). Secara teori, lapisan tambahan dapat dibuat menjadi fungsi identitas, tetapi optimizer sulit menemukan solusi itu melalui tumpukan lapisan nonlinear. Blok residual mengubah target menjadi $y = x + F(x)$, sehingga identitas cukup dipelajari dengan mendorong $F(x)$ mendekati nol (Slide 11–12). Pada backpropagation, turunannya menjadi $\partial y/\partial x = I + \partial F/\partial x$. Suku identitas menyalurkan gradien langsung ke lapisan awal tanpa melewati rantai perkalian Jacobian yang pada plain network dapat menyusut eksponensial (vanishing gradient; Sesi 02, Slide 16–18). Namun, degradasi tetap muncul meski BatchNorm dipakai, sehingga vanishing gradient bukan satu-satunya penyebab. Skip connection terutama memudahkan optimasi dan aliran gradien (He dkk., 2016).
3. Feature Extraction hanya melatih head baru: pada ResNet-18 sekitar 5.130 dari kurang lebih 11,18 juta parameter, sedangkan fine-tuning layer4 melatih kurang lebih 8,4 juta parameter (Slide 16). Karena parameternya sedikit, feature extraction cukup dengan data kecil dan risiko overfitting rendah, sedangkan fine-tuning membutuhkan data lebih banyak. Secara komputasi, backbone beku tidak memerlukan gradien bobot maupun optimizer state, sehingga memori dan waktu per epoch lebih kecil. Pada fine-tuning, gradien dari head baru yang masih acak dapat merusak bobot pretrained (destructive gradient updates), sehingga learning rate harus kecil (Slide 16; Yosinski dkk., 2014). Kriteria praktis: pilih feature extraction saat data sangat terbatas, domain mirip ImageNet, dan sumber daya kecil (Slide 15, 29). Pilih fine-tuning bertahap saat data cukup, domain berbeda, atau performa feature extraction sudah mencapai plateau.

4. Tujuan dari augmentasi adalah untuk meningkatkan variasi data untuk mengajarkan fitur yang tidak berubah (Slide 20-21). Data validasi dan pengujian dimaksudkan untuk mengevaluasi kinerja model pada data dunia nyata, oleh karena itu mereka harus memiliki distribusi aslinya. Ketika augmentasi acak menghasilkan hasil yang berisik sehingga membuat tidak mungkin membandingkan berbagai percobaan dan menggunakan penghentian dini yang memonitor kerugian validasi itu menyesatkan. Oleh karena itu baik data validasi maupun pengujian hanya mengandung transformasi deterministik (Resize, CenterCrop, Normalize) dan augmentasi dilakukan setelah membagi dataset dan tidak ada kebocoran data. Contoh dari pilihan buruk augmentasi:perubahan warna yang besar pada ColorJitter. Warna bulu dan pola adalah fitur yang membedakan jenis (seperti misalnya Russian Blue yang berwarna abu-abu biru), oleh karena itu mengubah warna akan menjadi mengubah fitur penentu dari label melanggar invarian semantik.
5. Catastrophic forgetting terjadi karena over adaptasi (Slide 28). Ketika head yang baru ditambahkan secara acak menghasilkan gradien yang besar yang menuju ke lapisan pretrained karena kerugian untuk tugas yang baru tidak memiliki batasan untuk mempertahankan fitur sebelumnya maka bobot akan menjauh dari solusi asli dan fitur umum seperti tepi dan tekstur akan ditimpa (Kirkpatrick dkk, 2017). Metode mitigasi pertama: learning rate yang berbeda. Di sini lapisan 4 memiliki laju pembelajaran 1e-4 dan kepala memiliki learning rate 1e-3. Ini berarti bobot tidak akan menjauh terlalu banyak dari model yang sudah dilatih sementara kepala belajar dengan cepat. Metode mitigasi kedua: gradual freezing. Di sini head terlebih dahulu dilatih kemudian lapisan yang lebih dalam dibekukan satu per satu (Slide 16,29; Howard & Ruder, 2018).

Referensi :

- Howard, J., & Ruder, S. (2018). Universal Language Model Fine-tuning for Text Classification. *Proceedings of ACL 2018*.
- He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep Residual Learning for Image Recognition. *CVPR 2016*.
- Ioffe, S., & Szegedy, C. (2015). Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift. *ICML 2015* (PMLR 37).
- Kirkpatrick, J., dkk. (2017). Overcoming catastrophic forgetting in neural networks. *PNAS, 114*(13).
- Li, X., Chen, S., Hu, X., & Yang, J. (2019). Understanding the Disharmony between Dropout and Batch Normalization by Variance Shift. *CVPR 2019*, hlm. 2682–2690.
- Yosinski, J., Clune, J., Bengio, Y., & Lipson, H. (2014). How transferable are features in deep neural networks? *NeurIPS 27*.